

高精度数据处理中的方法理论简介 (外推、误差传递、拟合与统计平均)

1 符号约定与基本假设

本文仅给出方法层面的理论简介，不涉及任何具体软件界面或实现细节。

1.1 数据与不确定度

设观测量为 x ，其标准不确定度 (standard uncertainty) 为 σ_x 。在误差传递与加权拟合中，默认假设不同输入量之间相互独立 (不相关)；若存在相关性，应使用协方差矩阵形式 (见后文)。

1.2 序列与极限

外推 (extrapolation) 处理的典型对象是一个收敛序列 $\{s_n\}$ (例如随基组/截断等级增大的能量序列)，目标是估计极限 $s_\infty = \lim_{n \rightarrow \infty} s_n$ ，并给出一个可信的不确定度估计。

2 序列外推方法 (Extrapolation)

2.1 三点外推 (默认三点公式)

给定三项 A, B, C (通常理解为逐步改进的三次近似)，一种常用的三点外推形式为

$$V = \frac{(C - B)^2}{B - A} + C, \quad (1)$$

其中 V 为外推值。该形式的特点：

- 仅需三点，无需额外模型参数；
- 对数据的尺度平移不敏感，但当 $B \approx A$ 时会产生数值不稳定 (分母接近零)；
- 适合用作“快速、保守”的三点极限估计，但不保证在所有类型序列上严格成立。

不确定度估计可采用保守的“与输入点差异上界”：

$$U = \max(|V - A|, |V - B|, |V - C|). \quad (2)$$

该 U 更像是“外推与已有数据的一致性差异”，而非统计意义上的标准差。

2.2 幂律模型外推 (Power-law extrapolation)

对许多数值近似（尤其是具有“截断阶数/基组大小”含义的序列），常见的误差模型为

$$E(x) = E_\infty + a x^{-p}, \quad (3)$$

其中 x 表示控制精度的参数（例如基组等级或截断指标）， E_∞ 为目标极限， a, p 为待定常数。若给定三组 $(x_1, E_1), (x_2, E_2), (x_3, E_3)$ ，可通过消元求解 p 并得到 E_∞ ：

$$R = \frac{E_1 - E_2}{E_2 - E_3}, \quad (4)$$

$$\frac{x_1^{-p} - x_2^{-p}}{x_2^{-p} - x_3^{-p}} = R, \quad (5)$$

$$a = \frac{E_1 - E_2}{x_1^{-p} - x_2^{-p}}, \quad E_\infty = E_1 - a x_1^{-p}. \quad (6)$$

特点与注意事项：

- 模型具有明确物理/数值动机（主导误差项为幂律衰减）；
- 对三点数据较敏感：若 $E_2 \approx E_3$ 或 $x_2^{-p} \approx x_3^{-p}$ ，会导致求解不稳定；
- 可在 p 已知/可约束时提高鲁棒性；也可通过多点拟合扩展为过定约束问题。

一种常见的保守不确定度估计是与参考点（通常取最高等级点 E_3 或用户指定列）做差：

$$U = |E_\infty - E_{\text{ref}}|. \quad (7)$$

2.3 Richardson 外推 / 序列加速

Richardson 外推的核心思想：若近似 $S(h)$ 具有渐近展开

$$S(h) = S + c h^p + \mathcal{O}(h^{p+1}), \quad (8)$$

则可组合不同步长 h_1, h_2 的近似以消去主导误差项，从而提高收敛阶。例如在已知 p 的情形，

$$S \approx \frac{h_2^p S(h_1) - h_1^p S(h_2)}{h_2^p - h_1^p}. \quad (9)$$

扩展到多点时，可构造外推表以递推消元更高阶误差项。特点：

- 对“具有明确阶数 p 的渐近误差”效果好；
- 对不满足光滑渐近展开、或含振荡/非解析误差的序列可能不稳定；
- 需要对有效阶数 p 有一定了解（或采用自适应估计）。

在实际应用中，若缺乏可靠的统计误差模型，一个常见的保守不确定度估计是选取参考项 S_{ref} （例如序列最后一项或某一指定近似）并取

$$U = |S - S_{\text{ref}}|. \quad (10)$$

该 U 反映的是“外推/加速值与参考项的差异”，并不必然等同于统计意义上的标准差；应结合序列差分与多种方法交叉验证。

2.4 Shanks 变换与 Wynn ε 算法

Shanks 变换与 Wynn ε 算法属于非线性序列变换，常用于加速线性收敛或对数收敛序列。其直观动机是用有理近似（Padé 逼近的思想）去逼近序列的极限。

最简单的加速形式与 Aitken 的 Δ^2 过程相关：

$$s'_n = s_n - \frac{(\Delta s_n)^2}{\Delta^2 s_n}, \quad \Delta s_n = s_{n+1} - s_n, \quad \Delta^2 s_n = s_{n+2} - 2s_{n+1} + s_n, \quad (11)$$

在 $\Delta^2 s_n$ 不接近零时可显著加速线性收敛。Wynn ε 算法提供了更系统的递推表构造，实际使用时通常直接基于递推实现而非手写公式。

特点：

- 对线性收敛序列经常有效，且与 Padé 近似有紧密联系；
- 可能出现除零或数值放大（当差分很小或序列噪声较大时）；
- 对强振荡序列未必优于 Levin 类方法。

2.5 Levin 变换（以 u -transform 为代表）

Levin 类变换通过引入“余项估计” ω_n 来构造对极限的更好估计，常用于缓慢收敛或交错振荡的序列。其一般形式可写为

$$S \approx \frac{\sum_{k=0}^n w_k \frac{s_k}{\omega_k}}{\sum_{k=0}^n w_k \frac{1}{\omega_k}}, \quad (12)$$

其中权重 w_k 与所选变体（ u, t, v 等）有关， ω_k 通常由差分（如 $s_{k+1} - s_k$ ）或启发式模型给出。

特点：

- 对交错/缓慢收敛序列往往优于 Shanks/Wynn；
- 依赖 ω_k 的质量：若余项估计退化（例如连续项相同导致“零权重”），需要额外处理；
- 仍可能对噪声敏感，应结合诊断量与对比分析使用。

3 误差传递方法 (Uncertainty Propagation)

3.1 一阶（线性化）误差传递

设输出为

$$y = f(x_1, \dots, x_m), \quad (13)$$

在输入不确定度较小、且 f 在工作点附近光滑时，可对 f 做一阶泰勒展开并得到标准不确定度的近似：

$$\sigma_y^2 \approx \sum_{i=1}^m \left(\frac{\partial f}{\partial x_i} \sigma_{x_i} \right)^2. \quad (14)$$

若输入量存在相关性，需使用协方差矩阵形式：

$$\sigma_y^2 \approx \mathbf{g}^T \mathbf{\Sigma} \mathbf{g}, \quad \mathbf{g} = \nabla f, \quad \Sigma_{ij} = \text{Cov}(x_i, x_j). \quad (15)$$

常见特点：

- 适用于“小不确定度 + 光滑函数”的局部近似；
- 对强非线性、非高斯、或大不确定度情形可能低估误差，需要更高阶或 Monte Carlo 方法。

3.2 偏导数的获取：解析/符号与数值差分

一阶误差传递依赖偏导 $\partial f / \partial x_i$ 。理论上可采用：

- 解析偏导：手工推导或符号计算 (symbolic differentiation) 得到精确表达；
- 数值偏导：当解析难以获得时，用有限差分近似。

中心差分是常用的二阶精度近似：

$$\left. \frac{\partial f}{\partial x} \right|_{x=x_0} \approx \frac{f(x_0 + h) - f(x_0 - h)}{2h}. \quad (16)$$

步长 h 的选择需在“截断误差 (随 h 变小)”与“舍入误差 (随 h 变小而放大)”之间折衷。对二阶中心差分，经验上可取

$$h \sim \varepsilon^{1/3} \max(1, |x_0|), \quad (17)$$

其中 ε 表示数值系统的相对机器精度；在多精度计算中， ε 随有效位数变化，从而 h 也应随精度自适应调整。

3.3 二阶 (Taylor) 误差传递：均值修正与方差的二阶项

当 f 的非线性不能忽略、且输入可近似视为**独立正态**随机变量 $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ 时，可在工作点 μ 附近作二阶展开：

$$f(\mathbf{X}) \approx f(\mu) + \mathbf{g}^\top \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^\top \mathbf{H} \Delta \mathbf{x}, \quad \Delta \mathbf{x} = \mathbf{X} - \mu. \quad (18)$$

其中 $\mathbf{g} = \nabla f$, $\mathbf{H}$ 为 Hessian 矩阵 ($H_{ij} = \partial^2 f / \partial x_i \partial x_j$)。

在该近似下，输出的**均值**与**方差**可写为

$$\mathbb{E}[f(\mathbf{X})] \approx f(\mu) + \frac{1}{2} \sum_{i=1}^m H_{ii} \sigma_i^2, \quad (19)$$

$$\text{Var}[f(\mathbf{X})] \approx \mathbf{g}^\top \Sigma \mathbf{g} + \frac{1}{2} \text{tr}((\mathbf{H} \Sigma)^2). \quad (20)$$

当 $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_m^2)$ (独立假设) 时，

$$\text{tr}((\mathbf{H} \Sigma)^2) = \sum_{i=1}^m \sum_{j=1}^m H_{ij}^2 \sigma_i^2 \sigma_j^2. \quad (21)$$

特点：

- 相比一阶线性化，二阶方法既能补偿非线性导致的均值偏移，也能加入 Hessian 对方差的二阶贡献；
- 该公式依赖“正态 + 小不确定度 + 光滑函数”等假设；若分布非高斯或函数存在定义域/不连续，建议使用 Monte Carlo。

3.4 Monte Carlo 误差传递

Monte Carlo 方法不显式依赖导数，而是根据输入量的概率分布进行随机抽样：

$$X_i^{(k)} \sim \mathcal{N}(\mu_i, \sigma_i^2), \quad Y^{(k)} = f(X_1^{(k)}, \dots, X_m^{(k)}), \quad k = 1, \dots, N. \quad (22)$$

随后用样本均值与样本标准差估计输出的期望与不确定度：

$$\bar{Y} = \frac{1}{N} \sum_{k=1}^N Y^{(k)}, \quad s_Y = \sqrt{\frac{1}{N-1} \sum_{k=1}^N (Y^{(k)} - \bar{Y})^2}. \quad (23)$$

特点：

- 可自然捕获高阶效应、非线性与截断/定义域带来的分布形变；
- 计算成本与样本数 N 成正比；实践中可用固定随机种子复现实验；
- 若采样命中函数定义域外（如 $x < 0$ 时 $\sqrt{x}$ ），对应样本会失败，需要丢弃或改用更合适的输入分布模型。

4 拟合方法 (Fitting)

4.1 最小二乘与加权 χ^2

给定数据点 $\{(x_i, y_i)\}_{i=1}^n$ 与模型 $y_{\text{model}}(x; \mathbf{p})$ ，最小二乘拟合通过最小化残差平方和：

$$\text{RSS}(\mathbf{p}) = \sum_{i=1}^n r_i(\mathbf{p})^2, \quad r_i = y_{\text{model}}(x_i; \mathbf{p}) - y_i. \quad (24)$$

当每个点具有标准不确定度 σ_i 且可视为独立高斯噪声时，常用加权 χ^2 ：

$$\chi^2(\mathbf{p}) = \sum_{i=1}^n w_i r_i(\mathbf{p})^2, \quad w_i = \frac{1}{\sigma_i^2}. \quad (25)$$

自由度 $\nu = n - k$ (k 为自由参数数)，缩减卡方 $\chi_\nu^2 = \chi^2/\nu$ 常用于判断误差模型是否与数据一致（理想情况下 $\chi_\nu^2 \approx 1$ ）。

4.2 线性模型：解析解与协方差

当模型对参数线性：

$$y \approx \sum_{j=1}^k p_j \varphi_j(x), \quad (26)$$

记设计矩阵 $X_{ij} = \varphi_j(x_i)$ ，则加权最小二乘的正规方程解为

$$\hat{\mathbf{p}} = (X^\top W X)^{-1} X^\top W \mathbf{y}, \quad (27)$$

其中 $W = \text{diag}(w_1, \dots, w_n)$ 。在经典近似下，参数协方差为

$$\text{Cov}(\hat{\mathbf{p}}) \approx \sigma^2 (X^\top W X)^{-1}, \quad \sigma^2 \approx \frac{\chi^2}{\nu}. \quad (28)$$

参数标准不确定度为 $\sigma(p_j) = \sqrt{\text{Cov}_{jj}}$ ；非对角元反映参数相关性。

4.3 非线性模型：局部线性化与雅可比矩阵

对非线性模型，可在最优点附近对残差做线性化：

$$\mathbf{r}(\mathbf{p} + \Delta\mathbf{p}) \approx \mathbf{r}(\mathbf{p}) + \mathbf{J} \Delta\mathbf{p}, \quad J_{ij} = \frac{\partial r_i}{\partial p_j}. \quad (29)$$

由此得到 Gauss-Newton 近似下的协方差估计：

$$\text{Cov}(\hat{\mathbf{p}}) \approx \sigma^2 (\mathbf{J}^\top \mathbf{W} \mathbf{J})^{-1}. \quad (30)$$

该公式与“对模型输出的雅可比 $\partial y / \partial \mathbf{p}$ ”等价（差一个符号），是许多非线性拟合不确定度评估的基础。

4.4 模型比较指标：AIC / BIC / R^2

为在不同模型之间权衡拟合优度与复杂度，可使用信息准则。以 RSS（或未加权残差平方和）为噪声尺度的简化形式：

$$\text{AIC} \approx 2k + n \ln(\text{RSS}/n), \quad (31)$$

$$\text{BIC} \approx k \ln n + n \ln(\text{RSS}/n). \quad (32)$$

R^2 （决定系数）常用于衡量解释方差比例：

$$R^2 = 1 - \frac{\sum_i r_i^2}{\sum_i (y_i - \bar{y})^2}, \quad (33)$$

但在非线性、无截距或加权情形需谨慎解释。

5 统计平均方法 (Statistics)

5.1 算术平均与标准误差

算术平均：

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i. \quad (34)$$

样本方差（无偏估计）：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad (n > 1) \quad (35)$$

均值的标准误差（standard error）：

$$\sigma_{\bar{x}} = \frac{s}{\sqrt{n}}. \quad (36)$$

5.2 加权平均（权重 $w_i = 1/\sigma_i^2$ ）

当每个点具有已知标准不确定度 σ_i （独立）时，加权平均为

$$\bar{x}_w = \frac{\sum_i w_i x_i}{\sum_i w_i}, \quad w_i = \frac{1}{\sigma_i^2}. \quad (37)$$

其均值标准不确定度为

$$\sigma_{\bar{x}_w} = \sqrt{\frac{1}{\sum_i w_i}}. \quad (38)$$

此外常用“有效样本量”衡量权重集中程度：

$$n_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}, \quad (39)$$

当权重差异很大时， n_{eff} 可能远小于 n 。

若希望用同一套权重给出“数据散布”的估计，一种常见的加权样本方差无偏形式为

$$s_w^2 = \frac{\sum_i w_i (x_i - \bar{x}_w)^2}{\sum_i w_i - \frac{\sum_i w_i^2}{\sum_i w_i}}, \quad (40)$$

当所有权重相等时退化为普通样本方差 s^2 ；并且该分母也可写为 $W(1 - 1/n_{\text{eff}})$ （其中 $W = \sum_i w_i$ ）。

6 常见实践建议（与方法无关）

- 外推/加速结果建议与原序列趋势、差分量和多种方法交叉验证；
- 误差传递若存在显著相关性，应提供协方差矩阵或改用 Monte Carlo；
- 拟合不确定度依赖模型正确性与噪声假设；出现强相关参数时应关注协方差/相关系数；
- 加权统计需检查 σ_i 的可信度，避免将系统误差当作纯统计误差处理。